



Apprentissage fédéré basé sur le clustering
pour la Prédiction du Diabète
Diyabet Tahmini için Küme Tabanlı Federe
Öğrenme

Alp Özcan — 22401007

Table des matières

1	Sujet du Projet de Fin d'Etudes	2
1.1	Domaine de recherche	2
1.2	Problématique	2
2	But(s) et Objectif(s)	3
3	Valeur Unique du Projet	3
4	Contribution Sociale ou Impact du Projet	3
5	Revue de Littérature	4
5.1	Gestion du diabète via des bandits à processus gaussiens (Çelik, 2021) . . .	4
5.2	Fusion probabiliste de processus gaussiens par Product of Experts (Cao & Fleet, 2015)	6
5.3	Apprentissage fédéré de processus gaussiens creux (Ashman et al., 2022) .	7
5.4	Federated Mixture of Experts (FedMix) – Reisser et al., 2021	8
5.5	Processus Gaussiens décentralisés et scalables (Kontoudis & Stilwell, 2022)	10
5.6	FedBNR : Régression neuronale bayésienne fédérée (Yu et al., 2022)	11
5.7	Approche PAC-Bayésienne pour le Personalized Federated Learning (Boroujeni et al., 2024)	12
5.8	Sélection automatique de variables latentes dans les processus gaussiens multi-sorties (Gao & Chung, 2024)	13
5.9	pFedGP : Apprentissage fédéré personnalisé avec processus gaussiens profonds (Achituve et al., 2021)	14
5.10	FedGMM : apprentissage fédéré personnalisé sous mélange de distributions (Wu et al., 2023)	15
6	Analyse SWOT	16
7	Méthodes/Technologies à Utiliser	16
8	Conception de Haut-Niveau	17
9	Calendrier de Travail	19

1 Sujet du Projet de Fin d'Etudes

La gestion des maladies chroniques, notamment le **diabète**, exige des modèles prédictifs capables d'adaptation continue tout en garantissant la sécurité des patients. Les **Processus Gaussiens (GP)** s'imposent comme une solution robuste grâce à leur capacité à quantifier l'incertitude épistémique. Cependant, deux lacunes majeures subsistent : la complexité computationnelle $O(N^3)$ qui limite le traitement de données massives et la protection de la confidentialité des données médicales sensibles stockées localement.

L'intérêt de coupler les GP avec l'**Apprentissage Fédéré (FL)** réside dans la fragmentation des calculs matriciels entre clients, permettant d'utiliser des approches de type *Product of Experts* (PoE) ou *Bayesian Committee Machine* (BCM) pour agréger des modèles locaux sans centraliser les données brutes. Cette synergie permet d'améliorer la scalabilité tout en maintenant une précision prédictive élevée et une calibration fiable des risques.

1.1 Domaine de recherche

Ce projet s'inscrit dans le domaine de l'Apprentissage Automatique appliquée à la santé, plus précisément dans l'utilisation des Processus Gaussiens et de l'Apprentissage Fédéré pour la prédiction du diabète.

L'objectif est de développer des modèles prédictifs fiables sans centraliser les données sensibles des patients.

1.2 Problématique

Les données médicales sont :

- sensibles et protégées par la loi,
- distribuées entre plusieurs hôpitaux,
- hétérogènes (les patients ont des profils très différents).

En même temps, les Processus Gaussiens sont précis et permettent de mesurer l'incertitude, mais ils sont coûteux en calcul.

Les questions principales sont donc :

- Comment entraîner un modèle performant sans partager les données ?
- Comment gérer les différences entre les patients ?
- Peut-on garder une bonne précision et une bonne estimation de l'incertitude dans un cadre fédéré ?

2 But(s) et Objectif(s)

Nous proposons de combiner :

1. Apprentissage Fédéré : chaque hôpital entraîne un modèle localement sans partager ses données.
2. Processus Gaussiens : pour obtenir des prédictions fiables avec une estimation de l'incertitude.
3. Méthodes d'agrégation probabiliste (ex : Product of Experts) : pour combiner les modèles locaux en un modèle global.
4. Processus Gaussiens creux (Sparse GP) : pour réduire le coût computationnel.

L'évaluation des performances sera réalisée à l'aide de différentes métriques classiques de classification et de régression, telles que l'accuracy, la précision, le recall, le F1-score et l'AUC-ROC. Ces métriques permettront d'analyser la capacité du modèle à prédire correctement le risque de diabète tout en conservant une estimation fiable de l'incertitude.

L'objectif final est de développer un modèle prédictif précis et scalable capable d'améliorer la détection précoce du diabète tout en garantissant la confidentialité des données médicales.

3 Valeur Unique du Projet

Ce projet se distingue des travaux existants par la combinaison du clustering local des données dans un cadre d'apprentissage fédéré avec des processus gaussiens probabilistes.

Contrairement aux approches classiques de Federated Learning basées sur des réseaux neuronaux, notre approche permet :

- une meilleure estimation de l'incertitude, - une meilleure interprétabilité, - une adaptation aux données hétérogènes entre hôpitaux.

4 Contribution Sociale ou Impact du Projet

Ce projet peut contribuer à l'amélioration des systèmes d'aide à la décision médicale pour le diabète.

L'utilisation de l'apprentissage fédéré permet de protéger les données sensibles des patients tout en améliorant la précision des modèles prédictifs.

Les résultats peuvent contribuer à :

- une détection plus précoce du diabète,
- une meilleure gestion des risques médicaux,
- et le développement de systèmes médicaux

basés sur l'intelligence artificielle respectant la confidentialité des données.

5 Revue de Littérature

5.1 Gestion du diabète via des bandits à processus gaussiens (Çelik, 2021)

Données utilisées Le travail de Çelik (2021) s’appuie principalement sur des données simulées issues du simulateur UVa/Padova pour le diabète de type 1, un environnement in-silico validé par la FDA et largement utilisé pour l’évaluation de systèmes de contrôle glycémique. Les expériences sont réalisées sur plusieurs patients virtuels représentant différentes caractéristiques physiologiques (adultes, adolescents et enfants). Les données incluent des séries temporelles de glycémie, des informations contextuelles telles que la glycémie à jeun, la quantité de glucides ingérés, le moment de l’injection d’insuline et les doses administrées. Ce cadre permet d’évaluer des politiques de décision dans un contexte réaliste tout en évitant les contraintes éthiques et pratiques des essais cliniques réels.

Méthodologie La méthodologie repose sur la modélisation du problème de gestion du diabète comme un problème de bandit contextuel à processus gaussien. Plus précisément, l’auteur introduit un algorithme VCGP-UCB (Volatile Contextual Gaussian Process Upper Confidence Bound), une extension des bandits GP contextuels intégrant la notion de traitements admissibles variables dans le temps. Le processus gaussien est utilisé pour modéliser la relation complexe et non linéaire entre le contexte patient, la dose d’insuline administrée et la réponse glycémique postprandiale. La sélection des doses repose sur un compromis exploration–exploitation guidé par la moyenne et la variance postérieures du GP, permettant une expérimentation sécurisée autour des recommandations standards issues de calculateurs cliniques.

Résultats principaux Les résultats montrent que l’approche proposée permet d’atteindre un contrôle glycémique comparable, voire supérieur, à celui obtenu par des cliniciens humains et par des méthodes classiques de régulation glycémique. L’algorithme présente une convergence théorique démontrée via une borne de regret sous-linéaire, garantissant que la fréquence des décisions sous-optimales tend vers zéro. De plus, la capacité du modèle à fournir des scores de confiance associés aux recommandations constitue un atout majeur pour l’évaluation du risque clinique.

Avantages L’approche bénéficie pleinement des propriétés bayésiennes des processus gaussiens : flexibilité non paramétrique, capacité à fonctionner dans des régimes de données limitées et quantification explicite de l’incertitude. Contrairement aux méthodes de contrôle en boucle fermée ou aux modèles de type deep reinforcement learning, elle reste interprétable et ne nécessite pas d’équipements médicaux coûteux tels que des pompes à insuline ou des capteurs CGM continus. L’algorithme peut être déployé sur des dispositifs légers et s’intègre facilement dans des systèmes d’aide à la décision clinique.

Limites Les expériences reposent principalement sur des données simulées, ce qui pose la question de la transférabilité vers des données réelles à grande échelle. Par ailleurs, le modèle est conçu pour un cadre centralisé ou individuel, sans prise en compte explicite de la collaboration inter-hôpitaux ou de l’apprentissage fédéré. Enfin, l’approche suppose que les observations successives peuvent être considérées comme indépendantes condi-

tionnellement au contexte, une hypothèse qui peut être limitante dans certains scénarios cliniques complexes.

Lien avec le projet Ce travail constitue une base conceptuelle essentielle pour notre projet, en démontrant l'adéquation des processus gaussiens pour la prise de décision personnalisée en diabétologie. Il motive l'extension de ces modèles vers un cadre fédéré multi-hôpitaux, où la personnalisation et la gestion de l'incertitude doivent être conservées tout en respectant les contraintes de confidentialité des données médicales.

5.2 Fusion probabiliste de processus gaussiens par Product of Experts (Cao & Fleet, 2015)

Données utilisées Les auteurs évaluent leurs méthodes sur plusieurs jeux de données de régression de grande taille, notamment KIN40K, SARCOS et un jeu de données de prix immobiliers au Royaume-Uni. Ces jeux de données sont caractérisés par des volumes importants et des dimensions élevées, rendant l'apprentissage exact de processus gaussiens impraticable. Les données sont partitionnées afin d'entraîner indépendamment de multiples experts GP, chacun ne disposant que d'un sous-ensemble limité des observations.

Méthodologie Le cadre du *Product of Experts* (PoE) combine les prédictions de plusieurs modèles probabilistes en multipliant leurs distributions conditionnelles, ce qui conduit à une pondération naturelle par la précision prédictive de chaque expert. Cependant, cette approche est sensible aux experts surconfiants mais mal calibrés. Pour pallier ce problème, Cao et Fleet proposent le *Generalized Product of Experts* (gPoE), dans lequel chaque expert est pondéré par un facteur de fiabilité dépendant de l'entrée. Dans le cas des processus gaussiens, ce facteur est défini comme la variation d'entropie entre le prior et le postérieur, mesurant l'information réellement apportée par un expert pour une prédiction donnée.

Résultats principaux Les expériences montrent que gPoE surpasse systématiquement les schémas de combinaison classiques tels que le bagging, les mélanges d'experts et le PoE standard, tant en termes d'erreur quadratique moyenne que de vraisemblance prédictive. Le modèle combiné reste un processus gaussien valide, avec une moyenne et une covariance analytiques, et démontre une grande robustesse face aux prédictions peu fiables de certains experts.

Avantages L'approche gPoE est hautement scalable, car les experts peuvent être entraînés indépendamment et en parallèle. Elle conserve une interprétation probabiliste claire et permet une agrégation dynamique dépendante de l'entrée, améliorant l'expressivité du modèle global. De plus, la pondération basée sur l'entropie agit comme un mécanisme automatique de filtrage des experts non informatifs.

Limites Le cadre gPoE ne permet pas de modéliser explicitement des distributions multimodales, contrairement aux mélanges d'experts. De plus, bien que la variation d'entropie soit un indicateur efficace de fiabilité, elle ne garantit pas théoriquement qu'un expert bien informé fournisse une prédiction correctement calibrée dans tous les cas.

Lien avec le projet Les méthodes de type PoE et gPoE sont directement pertinentes pour l'apprentissage fédéré de processus gaussiens, où chaque client peut être vu comme un expert local. Dans le contexte de la gestion du diabète, ces approches offrent un moyen principal d'agréger des modèles entraînés sur différents hôpitaux ou groupes de patients, tout en exploitant l'incertitude prédictive pour renforcer la sécurité des décisions cliniques.

5.3 Apprentissage fédéré de processus gaussiens creux (Ashman et al., 2022)

Données utilisées Les auteurs évaluent leur méthode sur des benchmarks classiques de régression issus du dépôt UCI (tels que *Boston Housing* et *Concrete*), ainsi que sur un jeu de données réel à grande échelle composé de mesures météorologiques européennes provenant de 1 648 stations. Ces données sont naturellement distribuées par station, ce qui correspond à un scénario réaliste d'apprentissage fédéré où chaque client possède un sous-ensemble local des observations. Le jeu de données météorologiques présente également une forte hétérogénéité spatiale et une distribution non uniforme des observations, ce qui constitue un défi majeur pour les modèles de processus gaussiens.

Méthodologie La contribution principale repose sur l'adaptation de l'inférence variationnelle partitionnée (Partitioned Variational Inference, PVI) aux processus gaussiens creux dans un cadre fédéré. Les auteurs reformulent les points d'induction comme des variables auxiliaires au sein d'un modèle variationnel hiérarchique, ce qui permet de factoriser l'inférence par client tout en conservant une cohérence globale. Une nouvelle paramétrisation, appelée *Decoupled Pseudo-Observations* (DPO), est introduite afin de découpler l'estimation de la moyenne et de la covariance du postérieur de la position des points d'induction. Cette paramétrisation améliore la stabilité numérique et facilite la convergence vers une solution globale équivalente à celle d'un GP variationnel centralisé.

Résultats principaux Les résultats expérimentaux montrent que la méthode proposée converge vers la solution du GP variationnel global, tout en surpassant significativement les méthodes de référence telles que FedAvg. De plus, le nombre de tours de communication nécessaires pour atteindre une performance comparable est considérablement réduit. Les prédictions obtenues présentent une meilleure quantification de l'incertitude, en particulier sur les jeux de données à grande échelle, ce qui est un atout essentiel pour les applications critiques.

Avantages Cette approche offre une excellente efficacité de communication grâce à l'optimisation variationnelle partitionnée. Elle respecte les contraintes de confidentialité, car seuls des paramètres variationnels sont partagés entre les clients et le serveur central. En outre, l'utilisation de points d'induction permet de rendre les processus gaussiens scalables à des jeux de données volumineux, ce qui était auparavant un obstacle majeur.

Limites La méthode nécessite le choix d'un nombre optimal de pseudo-observations par client, ce qui peut s'avérer délicat. Un nombre trop faible dégrade la qualité de la modélisation, tandis qu'un nombre trop élevé augmente la charge computationnelle sur les clients, ce qui peut être problématique pour des dispositifs aux ressources limitées.

Lien avec le projet Cette approche fournit une solution concrète au problème de la scalabilité matricielle des processus gaussiens dans un cadre fédéré. Elle est particulièrement adaptée à un scénario multi-hôpitaux pour la gestion du diabète, où des points d'induction partagés permettent d'apprendre une représentation globale tout en préservant la confidentialité des données des patients.

5.4 Federated Mixture of Experts (FedMix) – Reisser et al., 2021

Données utilisées

Les auteurs évaluent FedMix sur plusieurs jeux de données de classification d’images largement utilisés en apprentissage fédéré :

- **CIFAR-10** et **CIFAR-100**, avec des répartitions non-i.i.d. basées sur un biais de labels (label skew),
- **FEMNIST**, qui reflète naturellement une forte hétérogénéité entre utilisateurs,
- **MNIST roté**, afin de simuler une non-i.i.d.-ité sur la distribution des entrées,
- des scénarios de **permutation de labels** pour étudier des différences dans la relation $p(y|x)$ entre clients.

Les données sont réparties entre de nombreux clients, chacun conservant localement ses données sans partage direct avec le serveur central.

Méthodologie

FedMix repose sur le principe des *Mixtures of Experts* appliqué au cadre de l’apprentissage fédéré. Au lieu d’entraîner un unique modèle global (comme dans FedAvg), FedMix entraîne un ensemble de K experts spécialisés.

Chaque client apprend localement :

- un sous-ensemble d’experts pertinents pour ses données,
- une fonction de routage (gating mechanism) qui attribue probabilistiquement chaque donnée à un expert.

Pour gérer l’hétérogénéité des données, les auteurs introduisent une approximation variationnelle $q(z|y)$ permettant :

- d’encourager la spécialisation des experts,
- d’aligner les gradients entre clients ayant des distributions similaires,
- de contrôler le compromis entre spécialisation et robustesse via un paramètre d’entropie β .

L’agrégation côté serveur est effectuée expert par expert, ce qui réduit l’impact négatif des mises à jour divergentes dues aux données non-i.i.d.

Résultats principaux

Les résultats expérimentaux montrent que FedMix :

- surpasse systématiquement FedAvg en précision moyenne locale dans les scénarios fortement non-i.i.d.,
- converge plus rapidement grâce à une meilleure alignement des gradients,
- identifie correctement des groupes de clients partageant des caractéristiques similaires,
- améliore la personnalisation des modèles locaux après un léger fine-tuning.

Les gains sont particulièrement marqués dans les scénarios de biais de labels et de permutation de labels.

Points forts

- Gestion efficace de l’hétérogénéité des données entre clients,
- Modélisation plus flexible qu’un modèle global unique,
- Amélioration significative des performances personnalisées,

- Cadre probabiliste solide basé sur une borne variationnelle.

Limites et contraintes

- Coût de communication plus élevé dû à l'entraînement de plusieurs experts,
- Choix du nombre d'experts K non trivial et dépendant du problème,
- Complexité algorithmique supérieure à FedAvg,
- Risque de fuite d'information indirecte sur la distribution des labels dans certains cas.

Lien avec notre travail

FedMix est particulièrement pertinent pour notre projet, car il traite explicitement l'hétérogénéité des données entre clients, un problème central dans les applications de santé connectée. L'idée de modèles spécialisés partageant une information globale est conceptuellement proche des approches basées sur des experts locaux ou des processus gaussiens locaux dans un cadre fédéré, et peut inspirer des mécanismes de personnalisation plus avancés dans notre étude.

5.5 Processus Gaussiens décentralisés et scalables (Kontoudis & Stilwell, 2022)

Données utilisées Les auteurs utilisent des données synthétiques ainsi que des observations réelles de température de surface de la mer (Sea Surface Temperature, SST) dans l’océan Atlantique, comprenant jusqu’à 20 000 observations. Ces données sont réparties sur plusieurs agents, chacun représentant un capteur ou une unité de calcul indépendante, ce qui permet d’évaluer le comportement du modèle dans un environnement totalement décentralisé.

Méthodologie La méthodologie proposée repose sur des processus gaussiens entièrement décentralisés, sans serveur central. L’apprentissage des hyperparamètres est réalisé à l’aide de la méthode ADMM (Alternating Direction Method of Multipliers), adaptée à un contexte distribué. Pour l’étape de prédiction, différentes méthodes d’agrégation de type *Product of Experts* (PoE), *Bayesian Committee Machine* (BCM) et leurs variantes sont utilisées. Des algorithmes de consensus, tels que DAC et JOR, permettent aux agents de converger vers une prédiction globale uniquement par des communications locales.

Résultats principaux Les résultats montrent que la méthode DEC-NN-grBCM offre les meilleures performances en termes de précision et de quantification de l’incertitude. L’introduction de voisins basés sur la covariance permet de réduire significativement le nombre d’agents actifs sans perte notable de performance. Toutefois, la vitesse de convergence dépend fortement de la topologie du graphe de communication.

Avantages L’approche est totalement résiliente aux pannes d’un serveur central et réduit la congestion du réseau grâce à des communications locales entre agents voisins. Elle est particulièrement adaptée aux systèmes distribués à grande échelle et aux environnements IoT.

Limites La convergence peut être lente lorsque le diamètre du graphe de communication est élevé. De plus, certaines méthodes supposent une connectivité forte entre les agents, ce qui peut être irréaliste dans des scénarios pratiques.

Lien avec le projet Cette approche est pertinente pour des réseaux de dispositifs médicaux portables communiquant directement entre eux, sans dépendre d’une infrastructure cloud centralisée, ce qui renforce la robustesse et la confidentialité du système.

5.6 FedBNR : Régression neuronale bayésienne fédérée (Yu et al., 2022)

Données utilisées FedBNR est évalué sur plusieurs jeux de données de régression UCI, notamment Skillcraft, SML, Parkinsons, Bike Sharing et CCPP. Ces jeux de données présentent des distributions variées et permettent de tester la robustesse du modèle face à l'hétérogénéité des clients.

Méthodologie L'algorithme FedBNR vise à apprendre un processus gaussien global scalable dans un cadre fédéré. Il combine le *Deep Kernel Learning* avec une approximation de noyaux basée sur le *Unifying Random Kernel* (URK), permettant de représenter des noyaux infinis à l'aide de caractéristiques finies. L'agrégation fédérée repose sur le partage de matrices de dispersion plutôt que sur des noyaux explicites, ce qui permet une inférence exacte de la dernière couche linéaire tout en préservant la confidentialité.

Résultats principaux FedBNR surpasse significativement les méthodes FedAvg et pFedGP en termes de RMSE et d'erreur de calibration. Le modèle montre une grande stabilité face à l'hétérogénéité des clients, notamment grâce à un mécanisme de distillation de noyau.

Avantages Il s'agit du premier modèle capable d'apprendre un GP global fédéré scalable tout en garantissant la confidentialité des données. L'inférence bayésienne permet une excellente calibration des prédictions, essentielle pour les applications médicales.

Limites La méthode nécessite un petit jeu de données de distillation au niveau du serveur afin de gérer efficacement les distributions non-IID, ce qui peut constituer une contrainte dans certains contextes réglementaires.

Lien avec le projet FedBNR constitue une solution directe pour l'apprentissage d'un modèle global de gestion du diabète à partir de données issues de plusieurs hôpitaux, tout en limitant les risques liés au partage d'informations sensibles.

5.7 Approche PAC-Bayésienne pour le Personalized Federated Learning (Boroujeni et al., 2024)

Données utilisées Les auteurs évaluent leur approche sur des séries temporelles issues de systèmes photovoltaïques ainsi que sur les jeux de données d’images FEMNIST et EMNIST. Ces ensembles de données sont particulièrement adaptés à l’apprentissage fédéré personnalisé, car ils présentent une forte hétérogénéité inter-clients et des régimes de données très limités par utilisateur.

Méthodologie Le travail introduit le cadre *PAC-PFL*, qui s’appuie sur la théorie PAC-Bayésienne afin d’apprendre une hyper-postérieure partagée entre les clients. Chaque client apprend ensuite un postérieur personnalisé conditionné par cette hyper-postérieure globale. L’objectif est de minimiser une borne de généralisation PAC-Bayésienne, garantissant théoriquement un bon compromis entre biais et variance, même lorsque chaque client ne dispose que de très peu d’échantillons. L’inférence est réalisée à l’aide de la méthode SVGD (Stein Variational Gradient Descent) au niveau du serveur.

Résultats principaux Les résultats expérimentaux montrent que PAC-PFL fournit des prédictions nettement mieux calibrées que les méthodes fédérées classiques, même avec seulement une vingtaine d’échantillons par client. De plus, le modèle facilite un transfert d’apprentissage positif vers de nouveaux clients n’ayant jamais participé à l’entraînement initial.

Avantages L’approche offre de solides garanties théoriques de généralisation, ce qui est rare en apprentissage fédéré. Elle est particulièrement efficace dans les régimes de données extrêmement limités et réduit les risques d’overfitting local.

Limites La principale limite réside dans la complexité computationnelle de SVGD, qui impose une charge non négligeable au serveur central. Cette contrainte peut limiter le passage à l’échelle dans des systèmes à très grand nombre de clients.

Lien avec le projet Cette approche est cruciale pour un système de gestion du diabète, où de nouveaux patients peuvent rejoindre le dispositif avec très peu d’historique médical. Les garanties de généralisation assurent des recommandations fiables dès les premières observations.

5.8 Sélection automatique de variables latentes dans les processus gaussiens multi-sorties (Gao & Chung, 2024)

Données utilisées Les expériences sont menées sur des données de dégradation de batteries lithium-ion ainsi que sur des séries temporelles de températures de l'air. Ces données multi-sorties sont caractérisées par des dépendances latentes complexes et un bruit de mesure variable selon les capteurs.

Méthodologie Les auteurs proposent un modèle hiérarchique de corégionalisation linéaire (LMC) intégrant des priors de type *spike-and-slab* sur les coefficients des processus latents partagés. Cette formulation permet de forcer automatiquement à zéro les contributions des processus latents non pertinents. L'inférence est réalisée via une version fédérée de l'inférence variationnelle, permettant une sélection conjointe des composantes latentes et des paramètres du noyau.

Résultats principaux Le modèle FedLMC-SS identifie avec précision le nombre de processus latents nécessaires pour expliquer les données, par exemple six fonctions latentes dans des scénarios simulés complexes. Il surpasse les modèles MGP classiques en termes de précision d'extrapolation.

Avantages L'approche réduit automatiquement la dimensionnalité du modèle, évitant les optima locaux pauvres et améliorant la généralisation. Elle facilite également l'intégration de nouvelles unités ou capteurs sans reconfiguration manuelle du modèle.

Limites La phase de prédiction repose sur un échantillonnage de Monte-Carlo, ce qui peut engendrer un coût computationnel élevé lorsque le nombre de sorties ou de processus latents est important.

Lien avec le projet Cette méthode permet d'identifier les mécanismes physiologiques communs à l'ensemble des patients diabétiques, tout en ignorant les bruits spécifiques à chaque capteur ou individu, ce qui renforce la robustesse clinique du modèle.

5.9 pFedGP : Apprentissage fédéré personnalisé avec processus gaussiens profonds (Achituve et al., 2021)

Données utilisées Les auteurs évaluent pFedGP sur les benchmarks CIFAR-10, CIFAR-100 et CINIC-10, qui représentent des scénarios fortement non-IID et constituent des cas tests exigeants pour l'apprentissage fédéré personnalisé.

Méthodologie pFedGP apprend une fonction de noyau profonde partagée à l'aide d'un réseau neuronal, tandis que chaque client possède un classifieur GP personnalisé. L'inférence pour la classification est rendue tractable grâce à l'augmentation de Pólya-Gamma, permettant une formulation conjuguée. Des stratégies de points d'induction sont introduites pour améliorer la généralisation et réduire les coûts computationnels.

Résultats principaux Le modèle atteint des gains de précision allant jusqu'à 21 % sur CIFAR-100 par rapport aux méthodes de l'état de l'art. Il présente également une robustesse remarquable face au bruit et aux décalages de distribution.

Avantages pFedGP offre une excellente calibration des probabilités, ce qui est crucial pour les applications cliniques. Il est particulièrement efficace dans les régimes de données limitées et permet une personnalisation fine des modèles.

Limites Le stockage local des matrices de noyau peut devenir coûteux en mémoire pour des dispositifs aux ressources limitées, ce qui limite son applicabilité directe sur certains capteurs.

Lien avec le projet Ce modèle constitue une référence majeure pour la personnalisation des processus gaussiens en apprentissage fédéré. La qualité de la calibration est un atout essentiel pour la prise de décision dans le cadre du dosage d'insuline.

5.10 FedGMM : apprentissage fédéré personnalisé sous mélange de distributions (Wu et al., 2023)

Données utilisées Les auteurs évaluent FedGMM sur des jeux de données synthétiques ainsi que sur plusieurs benchmarks de classification présentant des distributions hétérogènes entre clients.

Méthodologie FedGMM modélise explicitement l'hétérogénéité inter-clients à l'aide d'un modèle de mélange gaussien. Chaque client est associé à une composante latente du mélange, et les paramètres sont appris via un algorithme EM adapté au cadre fédéré. Cette formulation permet de capturer le *covariate shift* et la multimodalité des distributions locales.

Résultats principaux Les résultats montrent une amélioration significative des performances par rapport aux méthodes PFL classiques, notamment dans les scénarios à forte hétérogénéité. Le modèle permet également une détection plus robuste des échantillons atypiques.

Avantages L'approche fournit une modélisation explicite de la diversité des clients et améliore la robustesse face aux distributions non-IID. La structure probabiliste permet une meilleure quantification de l'incertitude.

Limites L'hypothèse de mélange gaussien peut être restrictive dans des scénarios très complexes. De plus, l'algorithme EM fédéré peut présenter des problèmes de convergence lorsque les composantes sont mal séparées.

Lien avec le projet FedGMM est pertinent pour modéliser la diversité physiologique des patients diabétiques, en capturant explicitement différents profils métaboliques au sein d'un système fédéré personnalisé.

6 Analyse SWOT

Cette section présente une analyse SWOT du projet afin d’identifier ses forces, ses limites ainsi que les opportunités et risques potentiels liés à sa mise en œuvre.

Strengths (Forces)	Weaknesses (Faiblesses)
- Protection de la confidentialité des données grâce à l’apprentissage fédéré. - Capacité des processus gaussiens à quantifier l’incertitude des prédictions. - Possibilité de combiner plusieurs modèles locaux sans centraliser les données. - Modèle interprétable et adapté aux applications médicales critiques.	- Coût computationnel élevé des processus gaussiens pour de grands jeux de données. - Complexité de mise en œuvre dans un environnement distribué multi-clients. - Dépendance à la qualité et à l’hétérogénéité des données locales. - Besoin d’optimisation pour améliorer la scalabilité du modèle.
Opportunities (Opportunités)	Threats (Menaces)
- Croissance rapide des applications de l’IA dans le domaine médical. - Collaboration possible entre plusieurs hôpitaux sans partage de données sensibles. - Développement de systèmes d’aide à la décision clinique plus fiables. - Amélioration de la détection précoce et de la gestion du diabète.	- Contraintes réglementaires liées aux données de santé. - Risque d’hétérogénéité importante entre les données des clients. - Coût de communication dans les systèmes fédérés à grande échelle. - Difficulté d’intégration dans les infrastructures hospitalières existantes.

TABLE 1 – Analyse SWOT du projet

7 Méthodes/Technologies à Utiliser

L’implémentation du modèle proposé sera réalisée en Python en utilisant la bibliothèque **GPyTorch**, qui est spécialement conçue pour l’apprentissage de processus gaussiens scalables et compatibles avec les frameworks modernes d’apprentissage automatique tels que PyTorch. Cette bibliothèque permet une optimisation efficace des processus gaussiens grâce à des techniques d’approximation telles que les *Sparse Gaussian Processes*.

Dans notre approche, chaque client (représentant un hôpital ou une source de données) entraîne un modèle local basé sur des processus gaussiens. Les paramètres des modèles locaux sont ensuite combinés dans un cadre d’apprentissage fédéré à l’aide de méthodes d’agrégation probabilistes telles que le *Product of Experts*.

Les expérimentations seront réalisées sur des jeux de données liés au diabète provenant de sources publiques. Ces ensembles de données contiennent différentes variables médicales telles que :

- le niveau de glucose sanguin,
- la pression artérielle,
- l'indice de masse corporelle (BMI),
- le nombre de grossesses,
- l'âge des patients.

Ces caractéristiques seront utilisées pour entraîner et évaluer les modèles prédictifs. Les données seront partitionnées afin de simuler un environnement d'apprentissage fédéré dans lequel plusieurs clients possèdent chacun une partie des données.

8 Conception de Haut-Niveau

L'architecture proposée ne repose pas sur une communication directe entre plusieurs clients indépendants. Au contraire, chaque client traite localement ses propres données et réalise un partitionnement interne afin de mieux gérer l'hétérogénéité des profils médicaux.

Dans un premier temps, les données de diabète sont chargées et prétraitées. Ensuite, pour chaque variable étudiée, un mécanisme de clustering est appliqué localement afin de séparer les observations en sous-groupes homogènes selon des caractéristiques médicales ou statistiques.

Chaque sous-groupe obtenu est ensuite traité comme une unité locale d'apprentissage. Un modèle de processus gaussien est entraîné sur chaque cluster à l'aide de la bibliothèque **GPYtorch**. Dans notre implémentation, des *Exact Gaussian Processes* et des *Sparse Gaussian Processes* sont utilisés afin de réduire le coût computationnel.

Après l'entraînement local, une phase d'agrégation est réalisée pour combiner les résultats issus des différents clusters appartenant au même client. Cette agrégation permet d'obtenir un modèle global localement cohérent sans échange direct de données brutes entre différentes entités externes.

Cette architecture permet donc de mieux capturer l'hétérogénéité présente dans les données médicales, tout en conservant une structure modulaire, scalable et adaptée à la prédiction du diabète.




FIGURE 1 – Architecture générale du système proposé

9 Calendrier de Travail

Le déroulement du projet est organisé en plusieurs phases allant de la revue de littérature jusqu'à l'analyse des résultats expérimentaux.




FIGURE 2 – Diagramme de Gantt du projet

Références

- [1] Çelik, A. A. (2021). *Diabetes Management via Gaussian Process Bandits*. Master’s Thesis, Bilkent University.
- [2] Cao, Y., & Fleet, D. J. (2014). *Generalized Product of Experts for Automatic and Principled Fusion of Gaussian Process Predictions*. arXiv :1410.7827.
- [3] Ashman, M., et al. (2022). *Federated Learning of Sparse Gaussian Processes*. Preprint.
- [4] Reisser, M., et al. (2021). *Federated Mixture of Experts*. arXiv :2107.06724.
- [5] Kontoudis, G. P., & Stilwell, D. J. (2022). *Fully Decentralized, Scalable Gaussian Processes for Multi-Agent Federated Learning*. arXiv :2203.02865.
- [6] Yu, H., et al. (2022). *Federated Bayesian Neural Regression : A Scalable Global Federated Gaussian Process*. arXiv :2206.06357.
- [7] Boroujeni, M. G., et al. (2024). *Personalized Federated Learning of Probabilistic Models : A PAC-Bayesian Approach*. arXiv :2401.08351.
- [8] Gao, J., & Chung, S. (2024). *Federated Automatic Latent Variable Selection in Multi-output Gaussian Processes*. arXiv :2407.16935.
- [9] Achituve, I., et al. (2021). *Personalized Federated Learning with Gaussian Processes*. NeurIPS 2021.
- [10] Wu, Y., et al. (2023). *Personalized Federated Learning under Mixture of Distributions*. ICML 2023.